

Filtro de Kalman extendido

Josué González García

Introducción

El filtro de Kalman estándar (KF) asume que tanto la dinámica del sistema como el modelo de medición son **lineales**.

Sin embargo, muchos sistemas reales presentan **no linealidades**.
Por ejemplo:

- Movimiento de un robot móvil en el plano.
- Navegación con sensores como GPS e IMU.
- Control de drones o vehículos autónomos.

Introducción

Un sistema **no lineal** es aquel que **no cumple** con el principio de superposición y/o homogeneidad. Esto significa que la relación entre la entrada y la salida **no es proporcional** ni directamente predecible mediante una combinación lineal.

Introducción

Indicadores comunes de no linealidad:

- Presencia de funciones no lineales como: $\sin(x)$, $\cos(x)$, x^2 , etc.
- Multiplicación entre variables de estado o entre estado y entrada.
- Ecuaciones diferenciales con coeficientes variables o dependientes del estado.

Introducción

- El **EKF** es una extensión que permite trabajar con modelos no lineales al **linealizarlos localmente** mediante **expansión en serie de Taylor de primer orden**.

Estructura general del EKF

- Dado un sistema no lineal:

$$\mathbf{s}_k = \mathbf{h}(\mathbf{s}_{k-1}, \mathbf{u}_k) + \mathbf{q}_k$$

- Y un modelo de medición:

$$\mathbf{z}_{i,k} = \mathbf{g}(\mathbf{m}_i, \mathbf{s}_k) + \mathbf{r}_{i,k}$$

Estructura general del EKF

- La etapa de predicción del filtro consiste en:

$$\hat{\boldsymbol{\mu}}_k = \mathbf{h}(\boldsymbol{\mu}_{k-1}, \mathbf{u}_k)$$

$$\mathbf{H}_k = \nabla_{\mathbf{s}_{k-1}} \mathbf{h}(\mathbf{s}_{k-1}, \mathbf{u}_k) \Big|_{\mathbf{s}_{k-1} = \boldsymbol{\mu}_{k-1}}$$

$$\boldsymbol{\Sigma}_k = \mathbf{H}_k \boldsymbol{\Sigma}_{k-1} \mathbf{H}_k^T + \mathbf{Q}_k$$

Linealización de un robot móvil diferencial

$$\mathbf{s}_{k+1} = \mathbf{h}(\mathbf{s}_k, \mathbf{u}_k) = \begin{bmatrix} s_{x,k} + \Delta t \cdot v_k \cdot \cos(s_{\theta,k}) \\ s_{y,k} + \Delta t \cdot v_k \cdot \sin(s_{\theta,k}) \\ s_{\theta,k} + \Delta t \cdot \omega_k \end{bmatrix}$$

$$\mathbf{H}_k = \begin{bmatrix} \frac{\partial h_1}{\partial s_{x,k}} & \frac{\partial h_1}{\partial s_{y,k}} & \frac{\partial h_1}{\partial s_{\theta,k}} \\ \frac{\partial h_2}{\partial s_{x,k}} & \frac{\partial h_2}{\partial s_{y,k}} & \frac{\partial h_2}{\partial s_{\theta,k}} \\ \frac{\partial h_3}{\partial s_{x,k}} & \frac{\partial h_3}{\partial s_{y,k}} & \frac{\partial h_3}{\partial s_{\theta,k}} \end{bmatrix} = \begin{bmatrix} 1 & 0 & -\Delta t \cdot v_k \cdot \sin(\mu_{\theta,k}) \\ 0 & 1 & \Delta t \cdot v_k \cdot \cos(\mu_{\theta,k}) \\ 0 & 0 & 1 \end{bmatrix}$$

Ejemplo

- Dada las siguientes condiciones iniciales de un robot móvil diferencial

$$\boldsymbol{\mu}_0 = \begin{bmatrix} s_{x,0} \\ s_{y,0} \\ s_{\theta,0} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\boldsymbol{\Sigma}_0 = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

- Y considerando las siguientes constantes

$$\boldsymbol{Q}_k = \begin{bmatrix} 0.5 & 0.01 & 0.01 \\ 0.01 & 0.5 & 0.01 \\ 0.01 & 0.01 & 0.2 \end{bmatrix}$$

$$V_k = 2 \text{ m/s}$$

$$\omega_k = 1 \text{ rad/s}$$

$$\Delta t = 0.1 \text{ s}$$

Ejemplo

- Aplica la etapa de predicción del EKF para los siguientes dos instantes de tiempo

k	$\hat{\mu}_k$	H_k	$\hat{\Sigma}_k$
0			
1			
2			




Etapa de corrección

Objetivo de la corrección

- La corrección responde esta pregunta:
 - “¿Cómo ajusto mi posición estimada usando una medición real del entorno?”
- El EKF compara:
 - lo que el robot **esperaba medir**
 - lo que el sensor **realmente midió**
- La diferencia entre ambas se usa para corregir la posición.

Etapa de corrección

- En esta etapa el robot corrige su estimación de posición y orientación utilizando información proveniente de un sistema de medición distinto a la edometría, por ejemplo, mediante la identificación de landmarks (m_i) con posición conocida ($m_{x,i}, m_{y,i}$).



Etapa de corrección

- Se recibe una nueva medición

$$z_k = \begin{bmatrix} z_{\rho,i,k} \\ z_{\alpha,i,k} \end{bmatrix}$$

- En ese momento, la etapa de corrección inicia por calcular la medición esperada a partir de la posición y orientación estimados hacia el landmark identificado

$$\hat{z}_k = g(\hat{\mu}_{k-1}, m_i)$$

Etapas de corrección

- Posteriormente, se calcula el error de la medición como la diferencia entre la medición esperada y la real, a este termino se le conoce como innovación:

$$y_k = z_k - \hat{z}_k$$

- El siguiente paso es la linealización del modelo de mediciones por medio de la expansión por series de Taylor

$$G_k = \nabla_{s_k} g(\hat{\mu}_{k-1}, m_i)$$

Etapas de corrección

$$g_1 = \sqrt{(m_{x,i} - s_{x,k})^2 + (m_{y,i} - s_{y,k})^2}$$

$$g_2 = \text{atan2}((m_{y,i} - s_{y,k}), (m_{x,i} - s_{x,k})) - s_{\theta,k}$$

$$\Delta x = m_{x,i} - \hat{s}_{x,k} \quad \Delta y = m_{y,i} - \hat{s}_{y,k} \quad p = \Delta x^2 + \Delta y^2$$

$$\mathbf{G}_k = \begin{bmatrix} \frac{\partial g_1}{\partial s_{x,k}} & \frac{\partial g_1}{\partial s_{y,k}} & \frac{\partial g_1}{\partial s_{\theta,k}} \\ \frac{\partial g_2}{\partial s_{x,k}} & \frac{\partial g_2}{\partial s_{y,k}} & \frac{\partial g_2}{\partial s_{\theta,k}} \end{bmatrix} = \begin{bmatrix} -\frac{\Delta x}{\sqrt{p}} & -\frac{\Delta y}{\sqrt{p}} & 0 \\ \frac{\Delta y}{p} & -\frac{\Delta x}{p} & -1 \end{bmatrix}$$

Etapa de corrección

- Lo siguiente es obtener la covarianza de la innovación como

$$Z_k = G_k \hat{\Sigma}_k G_k^T + R_k$$

- Y se utiliza para encontrar la ganancia del filtro

$$K_k = \hat{\Sigma}_k G_k^T Z_k^{-1}$$

- Finalmente se actualiza la estimación de estados y la matriz de covarianzas

$$\mu_k \leftarrow \hat{\mu}_k + K_k (z_{i,k} - \hat{z}_{i,k})$$

$$\Sigma_k \leftarrow (I - K_k G_k) \hat{\Sigma}_k$$

Estructura general del EKF

- La etapa de corrección del filtro se ejecuta cuando se recibe una nueva medición $z_{i,k}$ y consiste en:

$$\hat{\mathbf{z}}_{i,k} = \mathbf{g}(\mathbf{m}_i, \hat{\boldsymbol{\mu}}_k)$$

$$\mathbf{Z}_k = \mathbf{G}_k \hat{\boldsymbol{\Sigma}}_k \mathbf{G}_k^T + \mathbf{R}_k$$

$$\mathbf{K}_k = \hat{\boldsymbol{\Sigma}}_k \mathbf{G}_k^T \mathbf{Z}_k^{-1}$$

$$\boldsymbol{\mu}_k = \hat{\boldsymbol{\mu}}_k + \mathbf{K}_k (\mathbf{z}_{i,k} - \hat{\mathbf{z}}_{i,k})$$

$$\boldsymbol{\Sigma}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{G}_k) \hat{\boldsymbol{\Sigma}}_k$$

Resumen del EKF

1. **function** EKF-Localisation ($M, \mu_{k-1}, \Sigma_{k-1}, \mathbf{u}_k, \mathbf{z}_{i,k}, \mathbf{Q}_k, \mathbf{R}_k$)
2. $\hat{\mu}_k \leftarrow \mathbf{h}(\mu_{k-1}, \mathbf{u}_k)$
3. $\mathbf{H}_k \leftarrow \nabla_{\mathbf{s}_{k-1}} \mathbf{h}(\mathbf{s}_{k-1}, \mathbf{u}_k)|_{\mathbf{s}_{k-1}=\mu_{k-1}}$
4. $\hat{\Sigma}_k \leftarrow \mathbf{H}_k \Sigma_{k-1} \mathbf{H}_k^T + \mathbf{Q}_k$
5. **if** $\mathbf{z}_{i,k}$ corresponds to landmark $\mathbf{m}_i \in M$
6. $\hat{\mathbf{z}}_{i,k} \leftarrow \mathbf{g}(\mathbf{m}_i, \hat{\mu}_k)$
7. $\mathbf{G}_k \leftarrow \nabla_{\mathbf{s}_k} \mathbf{g}(\mathbf{m}_i, \mathbf{s}_k)|_{\mathbf{s}_k=\hat{\mu}_k}$
8. $\mathbf{Z}_k \leftarrow \mathbf{G}_k \hat{\Sigma}_k \mathbf{G}_k^T + \mathbf{R}_k$
9. $\mathbf{K}_k \leftarrow \hat{\Sigma}_k \mathbf{G}_k^T \mathbf{Z}_k^{-1}$
10. $\mu_k \leftarrow \hat{\mu}_k + \mathbf{K}_k (\mathbf{z}_{i,k} - \hat{\mathbf{z}}_{i,k})$
11. $\Sigma_k \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{G}_k) \hat{\Sigma}_k$

Ejemplo etapa de corrección

- Un robot móvil con modelo diferencial se desplaza en un entorno plano. En el instante, detecta un **landmark** con posición conocida.

$$m_i = \begin{bmatrix} 5 \\ 5 \end{bmatrix}$$

- El robot ya tiene una estimación e incertidumbre predichas:

$$\hat{\mu}_k = \begin{bmatrix} 1.728 \\ 0.835 \\ 1 \end{bmatrix}$$

$$\hat{\Sigma}_k = \begin{bmatrix} 5.13 & -0.12 & -0.48 \\ -0.12 & 7.42 & 1.84 \\ -0.48 & 1.84 & 2.0 \end{bmatrix}$$

Ejemplo etapa de corrección

- La incertidumbre ya es grande porque:
 - nunca corregimos con sensores
 - sólo usamos el modelo cinemático
 - el error se acumuló
- PASO 1 — Medición real del sensor
 - Supongamos que el sensor mide:

$$z_k = \begin{bmatrix} 5.90 \\ -0.15 \end{bmatrix}$$

- donde:
 - 5.90 m → distancia al landmark
 - -0.15 rad → ángulo relativo

Ejemplo etapa de corrección

PASO 2 — Calcular la medición esperada

- Ahora el EKF calcula:
 - “Si realmente estoy en (1.728, 0.835), ¿qué debería medir?”
- Usamos el modelo de medición

$$g_1 = \sqrt{(m_{x,i} - s_{x,k})^2 + (m_{y,i} - s_{y,k})^2}$$

$$g_2 = \text{atan2}((m_{y,i} - s_{y,k}), (m_{x,i} - s_{x,k})) - s_{\theta,k}$$

Ejemplo etapa de corrección

$$g_1 = \sqrt{(5 - 1.728)^2 + (5 - 0.835)^2}$$

$$g_1 = \sqrt{(3.272)^2 + (4.165)^2}$$

$$g_1 = \sqrt{10.71 + 17.35}$$

$$g_1 = \sqrt{28.06}$$

$$g_1 \approx 5.297 \text{ m}$$

Ejemplo etapa de corrección

$$g_2 \approx \text{atan2}(4.165, 3.272) - 1.0$$

$$g_2 \approx 0.905 - 1.0$$

$$g_2 \approx -0.095 \text{ rad}$$

- **Medición esperada**
- El robot esperaba observar:
- distancia $\approx 5.297 \text{ m}$
- ángulo $\approx -0.095 \text{ rad}$
- pero el sensor reportó algo distinto.

$$\hat{z}_k = \begin{bmatrix} 5.297 \\ -0.095 \end{bmatrix}$$

Ejemplo etapa de corrección

PASO 3 — Innovación

- La innovación mide la diferencia:

$$y_k = z_k - \hat{z}_k$$

- Sustituyendo:

$$y_k = \begin{bmatrix} 5.90 \\ -0.15 \end{bmatrix} - \begin{bmatrix} 5.297 \\ -0.095 \end{bmatrix}$$

$$y_k = \begin{bmatrix} 0.603 \\ -0.055 \end{bmatrix}$$

Ejemplo etapa de corrección

PASO 4 — Jacobiano de observación

Jacobiano G_k

$$\bullet G_k = \begin{bmatrix} -\frac{dx}{\sqrt{q}} & -\frac{dy}{\sqrt{q}} & 0 \\ \frac{dy}{q} & -\frac{dx}{q} & -1 \end{bmatrix}$$

Sustituyendo:

$$\bullet G_k \approx \begin{bmatrix} -0.618 & -0.786 & 0 \\ 0.148 & -0.117 & -1 \end{bmatrix}$$

Ejemplo etapa de corrección

PASO 5 — Covarianza de innovación

Ruido del sensor:

$$R = \begin{bmatrix} 0.05 & 0 \\ 0 & 0.02 \end{bmatrix}$$

Ahora:

$$Z_k = G_k \hat{\Sigma}_k G_k^T + R$$

Resultado aproximado:

$$Z_k \approx \begin{bmatrix} 6.479 & 1.365 \\ 1.365 & 2.809 \end{bmatrix}$$

Ejemplo etapa de corrección

PASO 6 — Ganancia de Kalman

$$K_k = \hat{\Sigma}_k G_k^T Z_k^{-1}$$

Resultado aproximado:

La ganancia indica cuánto corregir cada variable:

- posición x
- posición y
- orientación θ
- usando el error observado.

$$K_k \approx \begin{bmatrix} -0.633 & 0.754 \\ -0.762 & -0.598 \\ -0.007 & -0.810 \end{bmatrix}$$

Ejemplo etapa de corrección

PASO 7 — Corrección de la media

Usamos:

$$\mu_k = \hat{\mu}_k + K_k y_k$$

Sustituyendo:

$$\mu_k = \begin{bmatrix} 1.728 \\ 0.835 \\ 1.000 \end{bmatrix} + \left[K_k \approx \begin{bmatrix} -0.633 & 0.754 \\ -0.762 & -0.598 \\ -0.007 & -0.810 \end{bmatrix} \right] \begin{bmatrix} 0.603 \\ -0.055 \end{bmatrix}$$

Resultado:

$$\mu_k \approx \begin{bmatrix} 1.304 \\ 0.407 \\ 1.040 \end{bmatrix}$$

Ejemplo etapa de corrección

PASO 8 — Corrección de covarianza

Finalmente:

$$\Sigma_k = (I - K_k G_k) \hat{\Sigma}_k$$

Resultado aproximado:

$$\Sigma_k \approx \begin{bmatrix} 2.233 & -1.714 & 0.516 \\ -1.714 & 1.395 & -0.405 \\ 0.516 & -0.405 & 0.140 \end{bmatrix}$$

Ejemplo etapa de corrección

Antes de corregir:

$$\hat{\Sigma}_k = \begin{bmatrix} 5.13 & -0.12 & -0.48 \\ -0.12 & 7.42 & 1.84 \\ -0.48 & 1.84 & 2.00 \end{bmatrix}$$

Después de observar el landmark:

$$\Sigma_k \approx \begin{bmatrix} 2.233 & -1.714 & 0.516 \\ -1.714 & 1.395 & -0.405 \\ 0.516 & -0.405 & 0.140 \end{bmatrix}$$

La incertidumbre disminuyó significativamente.

Ejemplo etapa de corrección

Conclusión

- La corrección del EKF:
 - predice dónde está el robot
 - compara esa predicción con sensores
 - calcula el error
 - decide cuánto confiar en la medición
 - corrige la posición
 - reduce la incertidumbre